

## Sieci neuronowe i sztuczna inteligencja – laboratorium 3

24.03.2023

Monika Błyszcz, 236623

Zadanie wykonano na domyślnej bazie danych `dataset.load_wine`, którą można bezpośrednio zaimplementować do Pythona ze `sklearn`. Bazę przygotowano za pomocą komendy: `X,y = datasets.load_wine(return_X_y=True)`

Następnie przetestowano wszystkie typy walidacji krzyżowej (łącznie 13, wymienione na uzyskanych wynikach na następnej stronie) i porównano używając następujących modeli oszacowania jak: `CROSS_VAL_SCORE` (pobiera średnią z foldów walidacji krzyżowej) oraz `CROSS_VALIDATE`: (który pozwala określić wiele metryk do oceny oraz zwraca zestawienie zawierające czasy dopasowania, czasy punktacji (i opcjonalnie wyniki treningowe oraz dopasowane estymatory) oprócz wyniku testu.). Poniżej przedstawiono kod implementujący opisane powyżej działania

```
1 from sklearn.model_selection import RepeatedKFold, LeaveOneOut, LeavePOut, StratifiedKFold, GroupKFold, \
2   StratifiedGroupKFold, LeaveOneGroupOut, LeavePGroupsOut, GroupShuffleSplit, TimeSeriesSplit, \
3   StratifiedShuffleSplit
4 from sklearn import datasets
5 from sklearn import svm
6 from sklearn.model_selection import cross_val_score
7 from sklearn.model_selection import ShuffleSplit
8 from sklearn.model_selection import cross_validate
9 from sklearn.model_selection import KFold
10
11 # prepare of data
12 X, y = datasets.load_wine(return_X_y=True) # load the wine data set to fit a linear support vector machine on it:
13 groups = y # group parameter
14 scoring = ['precision_macro', 'recall_macro'] # parameters for cross_validate
15 random_state = 200 # default parameter
16
17 print('Cross validation iterations') ##Cross validation iterators
18 print('-----')
19
20 ##### MODEL SVC
21 clf = svm.SVC(kernel='linear', C=1, random_state=0)
22 scores_val = cross_val_score(clf, X, y, cv=5)
23 scores_cross = cross_validate(clf, X, y, cv=5, scoring=scoring, return_train_score=True)
24 sorted(scores_cross.keys())
25 scores_cross1 = scores_cross['test_precision_macro']
26 scores_cross2 = scores_cross['test_recall_macro']
27 print('===== MODEL SVC =====')
28 print(f"1. Number of SVC, scores used in Average: %s" % (len(scores_val)))
29 print(f"2. Cross_val_scores -> accuracy: {scores_val.mean() * 100}, standard deviation: {scores_val.std()}") # The value of the mean and the 95% confidence interval of the estimate of the results
30 print(f"3. Cross_validate -> precision: {scores_cross1}, recall: {scores_cross2}")
31 print('-----')
32
33 # defined functions to calculate cross_validate and cross_val_score for single and group scores
34 new*
35 def printMetrics(name, cv): # single
36     print("\n ===== %s =====" % name)
37     print(cv)
38     scores_val = cross_val_score(clf, X=X, y=y, cv=cv, )
39     cross = cross_validate(clf, X=X, y=y, cv=cv, scoring=scoring, return_train_score=True, return_estimator=True)
40     sorted(cross.keys())
41     scores1 = cross['test_precision_macro']
42     scores2 = cross['test_recall_macro']
43     print(f"1. Number of %s, scores used in Average: %s" % (name, len(scores_val)))
44     print(f"2. Cross_val_scores -> accuracy: {scores_val.mean() * 100}, standard deviation: {scores_val.std()}") # The value of the mean and the 95% confidence interval of the estimate of the results
45     print(f"3. Cross_validate -> precision: {scores1}, recall: {scores2}")
46
47 new*
48 def printMetricsGroup(name, cv): # group
49     print("\n ===== %s =====" % name)
50     print(cv)
51     scores_val = cross_val_score(clf, X=X, y=y, cv=cv, groups=groups)
52     cross = cross_validate(clf, X=X, y=y, cv=cv, scoring=scoring, return_train_score=True, return_estimator=True)
53     sorted(cross.keys())
54     scores1 = cross['test_precision_macro']
55     scores2 = cross['test_recall_macro']
56     print(f"1. Number of %s, scores used in Average: %s" % (name, len(scores_val)))
57     print(f"2. Cross_val_scores -> accuracy: {scores_val.mean() * 100}, standard deviation: {scores_val.std()}") # The value of the mean and the 95% confidence interval of the estimate of the results
58     print(f"3. Cross_validate -> precision: {scores1}, recall: {scores2}")
59
60 ##### Cross-validation iterators for i.i.d. data #####
61 print("Cross-validation iterators for i.i.d. data")
62 # KFold
63 kf = KFold(n_splits=2)
64 printMetrics("KFold", kf)
65
66 # Repeated KFold
67 rkf = RepeatedKFold(n_splits=2, n_repeats=2, random_state=random_state)
68 printMetrics("Repeated KFold", rkf)
69
70 # LOO
71 loo = LeaveOneOut()
72 printMetrics("Leave One Out", loo)
73
74 # Leave P Out (LPO)
75 lpo = LeavePOut(p=2)
76 printMetrics("Leave P Out", lpo)
77
78 #####Cross-validation iterators with stratification based on class labels #####
79 print("Cross-validation iterators with stratification based on class labels ")
80 # Stratified K-fold
81 skf = StratifiedKFold(n_splits=3)
82 printMetrics("Stratified KFold", skf)
83
84 # Stratified Shuffle Split
85 sss = StratifiedShuffleSplit(n_splits=3)
86 printMetrics("Stratified Shuffle Split", sss)
87
88 # Random permutations cross-validation a.k.a. Shuffle & Split
89 ss = ShuffleSplit(n_splits=5, test_size=0.25, random_state=0)
90 printMetrics("Shuffle & Split", ss)
91
92 ##### Cross-validation iterators for grouped data #####
93 print("Cross-validation iterators for grouped data")
94 # Group KFold
95 gkf = GroupKFold(n_splits=2).get_n_splits(X, y, groups)
96 printMetricsGroup("Group KFold", gkf)
97
98 # StratifiedGroupKFold
99 sgkf = StratifiedGroupKFold(n_splits=3).get_n_splits(X, y, groups)
100 printMetricsGroup("StratifiedGroupKFold", sgkf)
101
102 # Leave One Group Out
103 logo = LeaveOneGroupOut().get_n_splits(X, y, groups)
104 printMetricsGroup("Leave One Group Out", logo)
105
106 # Leave P Groups Out
107 lpgo = LeavePGroupsOut(n_groups=2).get_n_splits(X, y, groups)
108 printMetricsGroup("Leave P Groups Out", lpgo)
109
110 # Group Shuffle Split
111 gss = GroupShuffleSplit(n_splits=2, test_size=0.5, random_state=0).get_n_splits(X, y, groups)
112 printMetricsGroup("Group Shuffle Split", gss)
113
114 ##### Cross validation of time series data #####
115 print("Cross validation of time series data")
116 # Time Series Split
117 tscv = TimeSeriesSplit(n_splits=3)
118 printMetrics("Time Series Split", tscv)
```

Dla każdego validatora zwrócono następujące parametry:

- `cross_validate`: precision, recall

- `cross_val_score`: accuracy, std, number of used in average

[illegible]

Analizując kod możemy zauważyć, że w ogólnym ujęciu najlepsze parametry dla obu metod uzyskał Shuffle – Spilt (precision: 0.9629, re-call: 0.9841, accuracy: 0.9466). Natomiast wyszczególniając na konkretne metody to:

- Najlepsze wyniki dla cross\_validate uzyskano dla: Shuffle-Split (precision: 0,9629, re-call: 0,9841)
- Najlepsze wyniki dla cross\_val\_score uzyskano dla: Stratified Shuffle Split (accuracy: 98.14).

Na podstawie wyników można wywnioskować, że lepszą metodą jest `cross_validate`, ponieważ zwraca więcej metryk oceny, co pozwala na dokładniejsze sprawdzenie strategii krzyżowej. Natomiast pod względem wyników lepszy jest `cross_val_score` bo uzyskuje wyższe wartości dokładności.